

SISTEMAS INTELIGENTES

APLICAÇÃO E ANÁLISE DE MÉTODOS DE REGRESSÃO

HEBERT ALAN KUBIS

DATABASE

A base de dados inclui uma ampla variedade de carros e suas respectivas características. Muitas dessas características estão descritas em linguagem natural, apresentando variações na escrita e eventuais erros de digitação.

TRATAMENTO DOS DADOS

INSTANCIAS INICIAIS: 8685

- Remoção de instancias sem preço, com preço inferior a \$ 1000 e as 1% com maior preço;
- Colunas removidas: faixa de preço, modelo, id e código da concessionária;
- Atributos de adesivos personalizados e couro transformados em binário;
- Conversão de categoria, combustível, tipo de câmbio, tração, fabricante e cor em colunas binárias;
- Agrupamento das cores “azul céu” com “azul” e “red” com “vermelho”;
- Volume do motor separado da característica de ser turbo;
- Instancias com volume do motor igual a zero foram descartadas;
- Quantidade de portas separadas em escala ordinal;
- Veículos com quilometragem faltante imputadas pela mediana da quilometragem dos veículos daquele mesmo ano;
- Rádio AM e FM separadas em duas colunas binárias;

INSTANCIAS FINAIS: 7772 (~20% DE REMOÇÃO)



MÉTRICAS DE DESEMPENHO

→ MAE (MEAN ABSOLUTE ERROR)

Média do erro absoluto, indicando a divergência média dos valores previstos em relação aos reais.

→ RMSE (ROOT MEAN SQUARED ERROR)

Raiz quadrada da média dos erros elevados ao quadrado, sendo sensível a erros grandes.

→ R^2 (R-SQUARED)

Coeficiente de determinação, que indica o quanto o modelo aprendeu sobre o comportamento das instancias trabalhadas.

MODELOS DE REGRESSÃO

K-Neighbors

K-NEIGHBORS

Determina o valor da variável de interesse com base nos K vizinhos mais próximos.

→ PARAMETROS

- n-neighbors = 10
- weights = 'distance'
- p = 1

Ridge

REGRESSÃO RIDGE

Aplica-se uma penalização para valores de pesos excessivamente altos que tentam ajustar a curva de forma excessivamente precisa aos dados de treinamento (Overfitting).

→ PARAMETROS

- α = 110

Decision Tree

DECISION TREE

Estabelece ramificações para agrupar características comuns a várias instâncias.

→ PARAMETROS

- max-depth = 15
- min_samples_split = 32
- min_samples_leaf = 6

Random Forest

RANDOM FOREST

Determina a saída com base em várias árvores de decisão que "votam", cada uma contribuindo com uma opção para uma determinada instância.

→ PARAMETROS

- n_estimators = 180
- max_depth = None
- min_samples_split = 2

MLP

MULTILAYER PERCEPTRON

Diversas camadas trabalham juntas ajustando pesos para produzir uma saída a partir de cada entrada.

→ PARAMETROS

- hidden_layer_sizes = 100
- activation = 'relu'
- learning_rate = 'constant'

RESULTADO

Modelo	MAE	RMSE	R ²
K-Neighbors	\$ 7085,93	\$ 10591,17	0,4909
Ridge	\$ 8096,72	\$ 11342,61	0,4160
Tree	\$ 5619,51	\$ 8890,14	0,6413
Forest	\$ 4691,95	\$ 7506,02	0,7443
MLP	5796,82	\$ 8840,99	0,6452

← Baseline

← Melhor desempenho


CONCLUSÃO

JUSTIFICATIVA PARA OS RESULTADOS

- O modelo Ridge, por ser um modelo linear, não consegue se ajustar a multidimensionalidade dos dados (por isso foi considerado a baseline para os outros modelos);
- O K-Neighbors se saiu um pouco melhor, mas foi comprometido pela grande quantidade de atributos binários da base;
- A Decision Tree teve um bom desempenho, visto que esta consegue criar bons agrupamentos de dados, principalmente com a grande quantidade de atributos binários da base;
- A MLP poderia ter tido um desempenho melhor se houvesse mais dados para treinar, mas com a pouca quantidade ela sofreu com overfitting.

MELHOR MODELO

A Random Forest obteve o melhor desempenho ao descrever os dados visto sua capacidade de criar ramificações condicionais complexas.



REFERÊNCIAS

COEFICIENTE DE DETERMINAÇÃO. WIKIPÉDIA, 2025. DISPONÍVEL EM: [HTTPS://PT.WIKIPEDIA.ORG/WIKI/COEFICIENTE DE DETERMINA%A7%C3%A3O](https://pt.wikipedia.org/wiki/Coeficiente_de_determina%C3%A7%C3%A3o). ACESSO EM: 13 DE JUNHO DE 2026.

CARROS A VENDA. CARROS.COM, 2026. DISPONÍVEL EM: [HTTPS://CARROS.COM/CARS-FOR-SALE/UTAH-CO240/](https://carros.com/cars-for-sale/utah-co240/). ACESSO EM: 13 DE JUNHO DE 2026.

MAE, MSE, RMSE, COEFFICIENT OF DETERMINATION, ADJUSTED R SQUARED — WHICH METRIC IS BETTER?. MEDIUM, 2020. DISPONÍVEL EM: [HTTPS://MEDIUM.COM/ANALYTICS-VIDHYA/MAE-MSE-RMSE-COEFFICIENT-OF-DETERMINATION-ADJUSTED-R-SQUARED-WHICH-METRIC-IS-BETTER-CD0326A5697E](https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared-which-metric-is-better-cd0326a5697e). ACESSO EM: 12 DE JUNHO DE 2026.

SUPERVISED LEARNING. SCIKIT-LEARN. DISPONÍVEL EM: [HTTPS://SCIKIT-LEARN.ORG/STABLE/SUPERVISED LEARNING.HTML](https://scikit-learn.org/stable/supervised_learning.html). ACESSO EM: 12 DE JUNHO DE 2026.

GROUND USER GUIDE. PANDAS. DISPONÍVEL EM: [HTTPS://PANDAS.PYDATA.ORG/DOCS/USER GUIDE/INDEX.HTML#USER-GUIDE](https://pandas.pydata.org/docs/user_guide/index.html#user-guide). ACESSO EM 12 DE JUNHO DE 2026.

BASIC USAGE. MATPLOTLIB. DISPONÍVEL EM: [HTTPS://MATPLOTLIB.ORG/3.5.1/TUTORIALS/INTRODUCTORY/USAGE.HTML](https://matplotlib.org/3.5.1/tutorials/introductory/usage.html). ACESSO EM: 12 DE JUNHO DE 2026.

COMO ALTERAR CSV EM PYTHON E PANDAS?. STACK OVERFLOW, 2019. DISPONÍVEL EM: [HTTPS://PT.STACKOVERFLOW.COM/QUESTIONS/362420/COMO-ALTERAR-CSV-EM-PYTHON-E-PANDAS](https://pt.stackoverflow.com/questions/362420/como-alterar-csv-em-python-e-pandas). ACESSO EM: 12 DE JUNHO DE 2026.

MATERIAL DE AULA DO CURSO DE SISTEMAS INTELIGENTES, MINISTRADO PELO PROFESSOR DR. PABLO ANDRETTA JASKOVIK.