

Aplicação e Análise de Métodos de Regressão

Hebert Alan Kubis

Engenharia Mecatrônica

Universidade Federal de Santa Catarina (UFSC)

Centro Tecnológico de Joinville, Brasil

Resumo—O presente artigo descreve a avaliação de algoritmos de aprendizado de máquina na previsão de preços de veículos usados. Após um rigoroso pré-processamento (limpeza, remoção de outliers e engenharia de atributos), cinco métodos (K-Neighbors, Ridge, Decision Tree, Random Forest e MLP) foram otimizados via Grid Search. Os resultados mostram que modelos baseados em árvores de decisão e ensembles superaram amplamente os baselines lineares, capturando com precisão as não-linearidades complexas do mercado automotivo.

Index Terms—Aprendizado de Máquina, Regressão, Previsão de Preços, Engenharia de Atributos, Otimização de Hiperparâmetros.

I. INTRODUÇÃO

O mercado de veículos usados possui precificação volátil, influenciada por quilometragem, especificações e estado de conservação. Abordagens tradicionais de avaliação costumam ser imprecisas. Neste contexto, o Aprendizado de Máquina surge como solução robusta. Este trabalho aplica e compara métodos de regressão em uma base automotiva, buscando a abordagem preditiva mais eficaz para estabelecer um baseline de desempenho sólido.

II. ANÁLISE DA BASE DE DADOS

A análise de desempenho de diferentes métodos de regressão iniciou-se pela exploração dos dados fornecidos. A base possui várias características de diversos carros, sendo cada veículo uma instância. O objetivo da inserção desses dados em um modelo é estimar o preço com base em seus atributos.

A primeira etapa consistiu em excluir da base de treino todas as instâncias nas quais o preço estava ausente. Adicionalmente, procedeu-se com a remoção de outliers, eliminando veículos com preços irreais inferiores a US\$ 1.000, bem como as instâncias que representavam o 1% dos veículos mais caros da base. Essa abordagem visou mitigar erros de digitação na variável alvo, assumindo que alguns veículos de superluxo também foram removidos no corte superior para estabilizar a matemática dos modelos. Esse filtro resultou na exclusão de aproximadamente 19% da base de treino inicial. Para reduzir a dimensionalidade e a redundância, a coluna "Faixa_Preço" foi removida, visto que esta informação já estava contida na variável contínua de preço.

O pré-processamento de variáveis categóricas transformou atributos como "Adesivos_personalizados" e "Couro" em valores binários. Em seguida, a técnica de One-Hot Encoding (dummy variables) foi aplicada aos atributos: "Categoria", "Combustível", "Tipo_cambio", "Tração", "Fabricante" e

"Cor", sendo que nesta última realizou-se um agrupamento semântico unindo "Azul_celu" com "Azul" e "Red" com "Vermelho" para reduzir a cardinalidade.

Outra etapa crucial da engenharia de atributos separou a informação do volume do motor do fato de o carro ser turbo (criando um novo atributo binário). Foram descartadas instâncias com volume de motor igual a zero, visto que a base não compreendia veículos puramente elétricos. O atributo "Portas" foi convertido em uma escala ordinal por ordem de grandeza (0 a 2), sob a premissa de que veículos com mais portas tendem a apresentar dinâmicas de preço distintas.

Para a variável de quilometragem ("Km"), os dados nulos foram imputados utilizando a mediana dos veículos agrupados pelo mesmo "Ano" de fabricação. Por fim, as funcionalidades de rádio foram separadas nas colunas binárias "AM" e "FM", e a coluna descritiva do "Modelo" do veículo foi excluída devido à sua altíssima cardinalidade (mais de 1.000 modelos distintos), o que geraria excesso de ruído nos algoritmos.

Após a higienização completa, constatou-se que cerca de 20% da base original de treino foi excluída, restando 7.772 das 8.685 instâncias iniciais. Ressalta-se que a base de testes foi submetida ao exato mesmo pipeline de tratamento, garantindo o alinhamento de matrizes.

III. MÉTRICAS DE DESEMPENHO

Para analisar e comparar a qualidade preditiva de cada modelo, foram adotadas as seguintes métricas estatísticas:

- **MAE (Mean Absolute Error):** Representa a média do erro absoluto, indicando em quantos dólares, em média, as previsões do modelo divergiram do preço real do veículo no mercado.
- **RMSE (Root Mean Squared Error):** Calcula a raiz quadrada da média dos erros elevados ao quadrado. Por utilizar uma penalidade quadrática, esta métrica é altamente sensível a erros grosseiros (outliers residuais), sendo excelente para verificar se o modelo cometeu equívocos absurdos de precificação.
- **R² (R-Squared):** O Coeficiente de Determinação mede a proporção da variância nos preços que é previsível a partir das variáveis de entrada. Atua como um medidor percentual (0 a 1) do quanto o modelo efetivamente aprendeu sobre o comportamento do mercado.

IV. TESTES E RESULTADOS

Para cada modelo foi feita uma busca automatizada de hiperparâmetros (Grid Search) utilizando o Coeficiente de

Determinação (R^2) como métrica de seleção, visto que ele fornece uma interpretação percentual direta de quão bem o modelo explica a variância dos dados. A otimização definiu as seguintes configurações: **K-Neighbors** ($n_neighbors = 10$, $weights = 'distance'$, $p = 1$), priorizando vizinhos próximos via distância de Manhattan; **Ridge** ($\alpha = 110.0$), aplicando forte regularização L2 para reduzir pesos de variáveis irrelevantes e evitar overfitting; **Decision Tree** ($max_depth = 15$, $min_samples_split = 32$, $min_samples_leaf = 6$), restringindo ramificações isoladas para forçar a generalização; **Random Forest** ($n_estimators = 180$, $max_depth = None$, $min_samples_split = 2$), criando um conjunto de árvores profundas para capturar padrões não-lineares; e **MLP**, que manteve a topologia padrão do Scikit-Learn (100 neurônios, ativação ReLU, taxa de aprendizado con) pois arquiteturas mais profundas sofreram sobreajuste neste volume de dados.

Deste modo, a tabela a seguir mostra os valores obtidos para as métricas determinadas no trabalho para cada um dos modelos testados:

Tabela I
DESEMPENHO DOS MODELOS

Model	MAE	RMSE	R^2
K-Neighbors	\$ 7085.93	\$ 10591.17	0.4909
Ridge	\$ 8096.72	\$ 11342.61	0.4160
Tree	\$ 5619.51	\$ 8890.14	0.6413
Forest	\$ 4621.95	\$ 7506.02	0.7443
MLP	\$ 5796.82	\$ 8840.99	0.6452




Figura 1. Comparação do Coeficiente de Determinação (R^2)

Para estabelecer a qualidade minimamente esperada (base-line) desta base de dados, considerou-se o desempenho da Regressão Ridge, um modelo linear simples. O R^2 de 0.416 obtido por este modelo define o limiar mínimo de aceitação, qualquer modelo preditivo para este mercado automotivo deve superar a marca de 41% de variância explicada para justificar sua complexidade. Conforme ilustrado na Fig. 1, o K-Neighbors obteve resultados marginalmente melhores, mas esbarrou no problema da alta dimensionalidade gerada pelas colunas binárias, que distorcem o cálculo da distância entre os veículos.

Por outro lado, o modelo Decision Tree apresentou um grande salto de precisão (R^2 de 0.64). O sucesso das árvores justifica-se pela sua capacidade de criar ramificações condicionais complexas (isolando, por exemplo, veículos a diesel, automáticos e de anos recentes em "nós" específicos de alto valor). Por fim, a Random Forest obteve o melhor resultado dentre os métodos testados, visto as características das árvores de criar condicionais complexas, se mostrando melhor que a MLP, sendo isto justificado pela grande quantidade de características binárias na base que impõe a necessidade de se ter muito mais dados do que o disponível para o treinamento para poder se ajustar as características.

V. CONCLUSÃO

O presente trabalho atingiu seu objetivo ao implementar e comparar um conjunto diversificado de modelos de Machine Learning para a previsão de valores de automóveis. O estudo demonstrou que o pré-processamento de dados — especialmente a remoção de outliers, o agrupamento de categorias e o tratamento de valores nulos — é tão vital para o sucesso preditivo quanto a escolha do algoritmo em si. Conclui-se que algoritmos baseados em agrupamentos não-lineares e múltiplos estimadores superaram significativamente métodos estatísticos lineares em bases de dados automotivas compostas por características mistas (categóricas e contínuas).

REFERÊNCIAS

- [1] Coeficiente de determinação. Wikipédia, 2025. Disponível em: https://pt.wikipedia.org/wiki/Coeficiente_de_determina%C3%A7%C3%A3o. Acesso em: 13 de junho de 2026.
- [2] Carros a venda. Carros.com, 2026. Disponível em: <https://carros.com/cars-for-sale/utah-co240/>. Acesso em: 13 de junho de 2026.
- [3] MAE, MSE, RMSE, Coefficient of Determination, Adjusted R Squared — Which Metric is Better?. Medium, 2020. Disponível em: <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared-which-metric-is-better-cd0326a5697e>. Acesso em: 12 de junho de 2026.
- [4] Supervised learning. Scikit-Learn. Disponível em: https://scikit-learn.org/stable/supervised_learning.html. Acesso em: 12 de junho de 2026.
- [5] User Guide. Pandas. Disponível em: https://pandas.pydata.org/docs/user_guide/index.html#user-guide. Acesso em: 12 de junho de 2026.
- [6] Basic usage. Matplotlib. Disponível em: <https://matplotlib.org/3.5.1/tutorials/introductory/usage.html>. Acesso em: 12 de junho de 2026.
- [7] Como alterar CSV em Python e Pandas?. Stack Overflow, 2019. Disponível em: <https://pt.stackoverflow.com/questions/362420/como-alterar-csv-em-python-e-pandas>. Acesso em: 12 de junho de 2026.
- [8] Material de aula do curso de Sistemas Inteligentes, ministrado pelo professor Dr. Pablo Andretta Jaskowiak.